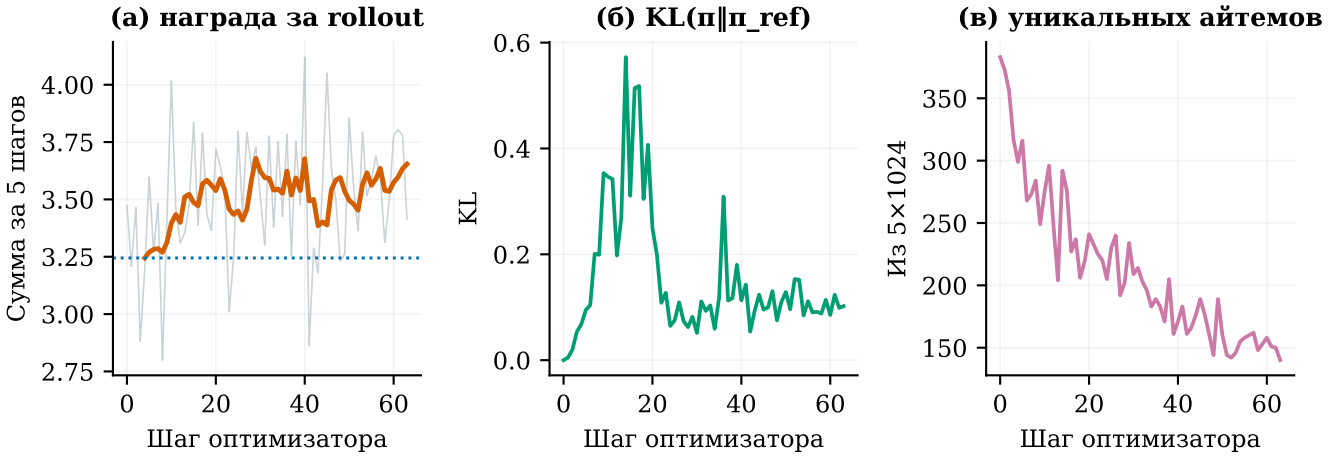
(а) награда за rollout
Сумма за 5 шагов
4.00
3.75
3.50
3.25
3.00
2.75
0
20
40
60
Шаг оптимизатора
(б) KL(π‖π_ref)
KL
0.6
0.4
0.2
0.0
0
20
40
60
Шаг оптимизатора
(в) уникальных айтемов
Из 5×1024
350
300
250
200
150
0
20
40
60
Шаг оптимизатора